

WORKSHOP 3

ETL

Salome Rivas Marulanda

Universidad Autónoma de Occidente

Facultad de ingeniería y ciencias básicas

ETL

Daniel Felipe Romero Bernal

2026

Descripción del dataset

Para este proyecto se utilizaron cinco archivos CSV correspondientes al World Happiness Report de los años 2015 a 2019. Cada archivo contiene información sobre el nivel de felicidad de diferentes países alrededor del mundo, medido a través del Happiness Score y diversas variables socioeconómicas.

- **Características de los datasets**

2015: 158 países, 12 columnas.

2016: 157 países, 13 columnas.

2017: 155 países, 12 columnas.

2018: 156 países, 9 columnas.

2019: 156 países, 9 columnas

El principal desafío fue que los nombres de las columnas cambiaron entre los años, lo que requirió un proceso de estandarización antes de unir los datasets.

Hallazgos del EDA

Tras unificar y limpiar los datasets, se realizó un análisis exploratorio completo que permitió identificar los siguientes hallazgos:

- El Happiness Score promedio se mantuvo estable entre 2015 y 2019, entre 5.3 y 5.5 puntos.
- Las variables GDP, Social Support y Life Expectancy presentaron la mayor correlación positiva con el Happiness Score, siendo las variables más fuertes.
- Corruption y Generosity mostraron correlaciones bajas con la variable de Happiness Score y una alta cantidad de outliers, por lo que fueron excluidas del modelo, aunque estos outliers no representen errores.
- Se identificó un único valor nulo en el dataset de 2018, el cual fue eliminado.

Selección y entrenamiento del modelo

Features seleccionadas:

Con base en el análisis de correlación del EDA, se seleccionaron 4 variables como features para el modelo:

- GDP
- Social Support
- Life Expectancy
- Freedom

Entrenamiento:

Se utilizó un modelo de Regresión Lineal de la librería scikit-learn. El dataset fue dividido en 70% para entrenamiento y 30% para prueba, usando la semilla 80 para garantizar la

consistencia. El modelo entrenado fue serializado como `model.pkl` para su uso en el sistema de streaming.

Métricas de evaluación

El modelo de Regresión Lineal fue evaluado usando dos métricas: R^2 y MAE. Con un R^2 de 0.76, el modelo explica el 76% de la variabilidad del Happiness Score usando únicamente 4 variables. El MAE de 0.43 indica predicciones bastantes cercanas a los valores reales. Se puede ver que la gráfica Real vs Predicho muestra que la mayoría de los puntos siguen bien la línea diagonal de referencia, confirmando que las predicciones son consistentes con los valores reales. La distribución de errores se concentra alrededor de cero sin un sesgo marcado, lo que indica que el modelo no tiende a sobreestimar ni subestimar. En conclusión, el modelo tiene un desempeño sólido considerando que es lineal y fue entrenado con sólo 4 variables. El 24% de variabilidad no explicada podría reducirse incorporando más variables o usando un modelo más complejo.

Proceso de streaming con Kafka

Configuración

Apache Kafka fue instalado manualmente en Windows debido a limitaciones de virtualización que me impedían usar Docker. Se usó Kafka 3.6.1 en modo KRaft (sin Zookeeper), lo que simplificó la configuración.

Producer

El Producer lee el 30% de datos de prueba (235 registros) del dataset `df_clean.csv` y los envía uno a uno al topic `happiness-features` en formato JSON. Cada mensaje contiene el `record_id`, las 4 features y el `actual_score`.

Consumer

El Consumer recibe cada mensaje del topic, carga el modelo `model.pkl` y genera una predicción del Happiness Score. Tanto las features como el score real y el score predicho son almacenados en una base de datos SQLite (`predictions.db`) para su posterior análisis.

El sistema procesó exitosamente los 235 registros, generando predicciones en tiempo real con un MAE de 0.43 y un R^2 de 0.76, resultados consistentes con los obtenidos durante el entrenamiento del modelo.